Demokršćanstvo: od riječi do argumenta

Detaljan plan analize za pregled

Samostalna dopuna analitičkom izvještaju 1.0

Metodološko uporište: Text Mining with R

Julia Silge i David Robinson | 19. rujna 2026.

2.306
zapisa u polaznoj zbirci

2.253
skupine jednakih tekstova

5
analitičkih modula

Koje ideje nose političko ime i kada postaju obrazloženje javne odluke?

Rječnik, fraze, načela, stavovi i trajnost sadržaja. Provjereno polazište; predložena analiza još nije izvedena.

Što će dopuna objasniti

Središnje pitanje: Kada je demokršćanstvo u ovoj zbirci oznaka političkog identiteta, a kada postaje obrazloženje odnosa prema radu, solidarnosti, slobodi, obitelji, Europi i javnoj vlasti?

Predlaže se samostalna dopuna postojećem izvještaju. Ona polazi od njegovih nalaza i ispituje sadržaj koji se gubi u broju spominjanja i jednoj primarnoj temi. Mogući zaključci ostaju otvoreni: razvijeni argumenti mogu biti raspršeni kroz zbirku, koncentrirani u nekoliko izjava ili slabo vidljivi zbog načina odabira teksta.

Modul	Pitanje i novi doprinos	Plan
M1. Prepoznatljiv rječnik	Koje riječi razlikuju kontekste i razdoblja, uz učestalost i rasprostranjenost?	str. 7
M2. Fraze i odnosi	Koje su veze ponavljane formule, a koje vode do različitih obrazloženja?	str. 8
M3. Načelo i primjena	Koje se vrijednosti izričito povezuju s problemom i prijedlogom ili prosudbom?	str. 9-10
M4. Stav i govorni glas	Tko procjenjuje tradiciju, stranku ili politiku i razlikuju li se ti stavovi?	str. 11
M5. Trajnost sadržaja	Pojavljuje li se određeni argument u više razdoblja, izvora i formulacija?	str. 12

Preporučeni redoslijed

Prvo: M1 i M2, priprema kodiranja M3 te opisna provjera raspršenosti M5. Dostupni tekst i jezični međurezultati omogućuju početak bez nove pretrage arhive.

Zatim: M3 i ciljano kodiranje stava u M4 na uzorku s poznatim vjerojatnostima izbora. To je najveći sadržajni dobitak i glavno mjesto na kojem su potrebni neovisni čitatelji.

Uvjetno: hrvatski leksički sentiment i dodatni tematski model. Uključiti ih samo ako pilot pokaže korist za pitanje koje jednostavniji postupak nije razriješio.

Za pregled: predložena jezgra ima pet modula, osam vrsta prikaza i dvije razine izvedbe. Kriteriji kvalitete i rezervni ishodi nalaze se na str. 13-14; isporuke i radni slijed na str. 16.

Dopuna počinje od postojećih podataka

Pregledani su izvorni PDF, njegov kod i agregati, manifesti te struktura i broj zapisa u privatnoj tekstualnoj datoteci. SHA256 izvornog PDF-a odgovara manifestu. Ova provjera potvrđuje polazište za plan; nije nova provjera svih interpretacija ni ponovno izvođenje cijele analize. [L1-L3]

Dostupno i provjereno	Posljedica za novu analizu
2.306 zapisa; 1. 1. 2021. - 10. 9. 2026.	Zamrznuti obuhvat. Ne proširivati ga neprimjetno na sve zapise o kršćanstvu ili politici.
2.253 skupine jednakog naslova i tijela; 1.731 različit dokazni kontekst	Glavna jezična jedinica: predstavnik točnog teksta. Kontekst nije neovisna priča.
2.211 pogodaka pravilom A1; 95 dodatnih	Pokazati osjetljivost na način uključivanja. Nazivlje koje bira korpus nije neovisno otkriće.
2.290 zapisa s osnovom pohranjenog tijela; 16 s osnovom isječka	Dostupnost polja nije jamstvo cjelovitog članka ili prijepisa.
2.198 nepraznih očišćenih tijela; 2.306 nepraznih naslova	Nakon uklanjanja ponovljenog naslova i šablona tijelo može biti prazno. Sačuvati smisleni naslov.
7.467 rečeničnih jedinica u postojećoj leksičkoj analizi; 187.597 provjerenih položaja tokena	Postoje leme, glagoli, negacija i položaji. Novi prošireni prozori ipak traže dodatnu anotaciju.
Web: 1.811 zapisa; 2025. web 212, tisak 41, Facebook 14, X 11	Detaljne usporedbe malih platformi nisu obećana jezgra.

Što izvještaj već radi

Postojeći izvještaj donosi vremensku vidljivost, deset NMF tema, kontrole kopija, NPMI odabranih pojmova i kvalitativne primjere primjene načela. Dopuna neće ponovno predstavljati te postupke kao novost. Dodaje pregled razlikovnog rječnika, izvorne fraze, sustavno kodiranje argumenta i njegovu raspršenost.

Otvorena granica: postojeće čitanje uz pomoć AI-ja i pripremljeni paket od 200 jedinica nisu dovršena ljudska validacija. Nema potvrđenih stopa točnosti ni populacijskih udjela novih sadržajnih oznaka. Novi nazivnici neće se preuzimati iz pripremljenog paketa. [L3]

Metode iz knjige, pitanja iz korpusa

Knjiga **Text Mining with R: A Tidy Approach** Julije Silge i Davida Robinsona daje metodološki okvir. Nije izvor tvrdnji o demokršćanstvu. U nastavku se njezini postupci prilagođavaju hrvatskom jeziku, selekciji korpusa i već provedenoj analizi. [1-6]

Dio knjige	Što preuzimamo	Konkretna prilagodba
1. Tidy text format	Jedan token u retku; povezivanje s metapodacima	Sačuvati izvorni oblik, lemu, rečenicu, polje, položaj i ključ tekstualne skupine.
3. Učestalost i TF-IDF	Razlikovanje čestih i dokumentu svojstvenih riječi	Dokument je lokalni sadržaj jednog točnog teksta; rijetkost nije sadržajna važnost.
4. N-grami i korelacije	Slijed riječi, supojavljivanje i binarna povezanost	Fraze graditi prije uklanjanja funkcijskih riječi; granice rečenica i negaciju sačuvati.
2. Sentiment	Povezivanje riječi s leksikonom; provjera doprinosa pojedinih riječi	Hrvatski rječnik i pilot pokrivenosti. Ton teksta odvojiti od stava prema određenom cilju.
5. Pretvorbe formata	Prijelaz između tablica i rijetkih matrica	Zadržati dokumente bez pogodaka u nazivnicima; koristiti brojanja ili težine prema metodi.
6. Tematsko modeliranje	Pregled riječi po temi i tema po dokumentu	Postojeći NMF ostaje referenca. LDA je moguća dopunska provjera na brojanjima, ne obvezan novi model.

Dvije korisne nadogradnje

Razlikovni rječnik: tidylo nudi težinski log-omjer izgleda s regularizacijom. Koristit će se kao dopuna opisnom TF-IDF-u, uz sirove brojeve i provjeru utjecaja pojedinog teksta ili citata. Njegov rezultat služi rangiranju, a ne dokazu javne važnosti pojma. [7]

Sadržajni kodni okvir: Kompendij socijalnog nauka i platforma EPP-a iz 2012. pomažu sastaviti početne pojmove i negativne primjere. Jedan je doktrinarni, drugi politički izvor određenog aktera i vremena. Nijedan nije univerzalni test pripadnosti demokršćanstvu. [8-9]

Izbor projekta: preskačemo oblak riječi i samostalnu provjeru Zipfova zakona. Oni ovdje ne odgovaraju na ključno pitanje o vezi načela i konkretnog argumenta. Prioritet dobivaju usporedive tablice, kontekst i provjerljive veze.

Koje napetosti vrijedi istražiti

Ovo su početne istraživačke osi, a ne unaprijed potvrđene dimenzije korpusa. Socijalna načela, političke oznake i područja javne politike vode se zasebno. Činjenica da se solidarnost ili obitelj spominju u tekstu nije sama po sebi dokaz demokršćanske argumentacije. [8-9; L1]

Os	Što tražiti u raspoloživom tekstu	Što bi promijenilo početno tumačenje
Identitet i odgovornost	Samoodređenje; opravdavanje odluke; kritika nedosljednosti aktera	Isti akter ili iskaz odbija stranku, ali prihvaća načela.
Osoba i opće dobro	Dostojanstvo, prava, odgovornost zajednice; određeni korisnik ili problem	Pojam ostaje u sloganu ili označuje čast pojedine organizacije.
Solidarnost, rad i gospodarstvo	Radni uvjeti, siromaštvo, javna zaštita, odnos tržišta i odgovornosti	Solidarnost je samo dio naziva ili popisa vrijednosti.
Supsidijarnost i vlast	Obrazložen odnos osobe, obitelji, udruga, lokalne vlasti, države i EU-a	Razine vlasti samo su nabrojane, bez načela raspodjele odgovornosti.
Obitelj, savjest i sloboda	Obrazloženje konkretne prosudbe, prava ili mjere	Isti rječnik podupire različite ili suprotstavljene prosudbe.
Europa, nacija i pluralizam	Odnos europske suradnje, nacionalnog identiteta i demokratskog poretka	Navod o stranoj stranci ne govori o domaćem političkom stavu.

Tri provjerljive pretpostavke

P1. Formule identiteta mogu biti učestale zbog prenošenja malog broja izjava. Provjera: promjena njihova ranga nakon kontrole citata i najvećeg izvora. Stabilan rang u različitim formulacijama oslabio bi objašnjenje ponavljanjem.

P2. Načela mogu biti povezana s problemima i izvan tema čiji naziv zvuči programski. Provjera: kodirati primjenu neovisno o NMF temi; pokazati potvrđene i promašene veze.

P3. Negativan jezični ton može pratiti afirmaciju tradicije i kritiku stranke. Provjera: u istom iskazu odvojiti cilj procjene i govornika. Ako se takvi kontrasti ne potvrde, ne isticati ih kao opći obrazac.

Pitanja o odsutnim idejama ostaju ograničena na dostupni odabrani tekst. Za tvrdnju o cijelom javnom govoru potreban je zaseban dizajn obuhvata.

Svaki nalaz mora voditi natrag do teksta

Glavna jedinica za leksičke module: jedan predstavnik svake od 2.253 postojeće skupine jednakog teksta. Zadržati prethodno pravilo izbora predstavnika. Za broj medijskih objava ostaje jedinica arhivski zapis; nijedna od tih jedinica nije automatski jedna izjava ili priča. [L1-L2]

Dva jasno odvojena opsega čitanja

Lokalni opseg: za usporedive jezične izračune koristiti izvorne rečenice koje dodiruju dokazne prozore. Preklapanja unutar polja objediniti. Po potrebi proširiti na jednu neposredno prethodnu i sljedeću rečenicu, ali prošireni opseg objaviti kao zasebnu osjetljivost.

Širi opseg: za kodiranje argumenta pročitati cijeli dostupni očišćeni tekst, uz naslov. Potvrditi vezu argumenta s demokršćanskim referentom; nepovezani odlomak istoga članka ne prenosi mu automatski značenje. Dugi prijepis i isječak dobivaju oznaku ograničenosti.

Tablica	Minimalna polja i pravilo
documents	record_key, exact_group, datum, platforma, pravilo uključivanja, text_basis; naziv izvora naknadno povezati iz privatnih kandidata
sentences / tokens	field, sentence_id, izvorni raspon, token, lemma, upos, negacija; položaji vrijede u istom normaliziranom polju
phrase_hits	verzija rječnika, phrase_id, početak i kraj; fraza ne prelazi granicu polja ili izvorne rečenice
claims / codes	claim_id, exact_group, govornik, cilj, načelo, problem, veza, status, dokazni raspon, koder i verzija pravila

Hrvatski jezik i metapodaci

Zadržati dijakritike i izvorni oblik uz lemu. Provjeriti oblike demokršćanstva, supsidijarnosti, stranaka i osobnih imena. Hrvatski popis funkcijskih riječi prilagoditi zadatku: ne uklanjati automatski ne, nije, protiv, ali ni ključne glagole argumentacije. Fraze prepoznavati prije filtriranja tokena. [1, 3]

Sadašnja datoteka documents.jsonl nema source_name, URL ni autora. Naziv izvora može se povezati iz privatnih kandidata uz provjeru ključa 1:1; URL i autor nisu preduvjet jezgre. Izdavač nije govornik. Redci bez teksta ili s nepoznatim izvorom ostaju u evidenciji nedostajućih podataka. [L2]

Što je često, a što sadržajno razlikovno?

Doprinos: pokazati rječnik koji postojeća tematska karta ne prikazuje izravno. Za svaki pojam odvojiti broj pojavljivanja, broj tekstova, broj razdoblja i broj različitih formulacija. Riječ koju mnogo puta ponavlja jedan dugi tekst ne smije izgledati široko zastupljeno.

Izračun i unaprijed određene usporedbe

1. Iz lokalnog opsega svakog predstavnika izvesti brojanja lema i zasebno brojanja fraza. Prikazati dokumentnu učestalost i učestalost na 10.000 zadržanih leksičkih tokena, uz navedeni nazivnik. Naslove ne dodavati ponovno ako su već dio tijela.

2. Izračunati TF-IDF po tekstualnoj skupini. Zbirni rang koristiti kao prosjek preko svih skupina, uključujući nule; sačuvati i pojedinačne rezultate. Za sadržajne osi prikazati 10-15 kandidata, uz potporu i kontrastne kontekste. Nazivlje uključivanja i vlastita imena prikazati zasebno. [2]

3. Primarni vremenski kontrast: web 2021. prema webu 2023., unutar starog režima. Polazni brojevi jesu 516 i 275 zapisa; broj predstavnika tek će se izvesti. Dopunski kontrast: siječanj-kolovoz 2025. prema istim mjesecima 2026., ako obje strane imaju barem 50 predstavnika. [L2]

4. Težinski log-omjer izgleda računati na istom rječniku i točno dvjema uspoređenim skupinama; prior iz njihova združenog korpusa. Uz rang pokazati broj tekstova i veličinu razlike. Prag z-vrijednosti ne koristiti kao dokaz statističke značajnosti. [7]

5. Nakon kodiranja M3 istražiti razlike između tekstova s potvrđenom primjenom i tekstova s identitetskom uporabom bez nađene primjene. Iz tog kontrasta izostaviti izravne riječi koje definiraju kodove; rezultat ipak ostaje opis uvjetovan kodiranjem.

Kontrole i prikaz

U vremenskom kontrastu brojiti jednu skupinu teksta jednom u svakom razdoblju u kojem je zabilježena, prema svim članovima skupine. Navesti broj skupina prisutnih na obje strane i ponoviti usporedbu bez njih. Glavni popis traži najmanje 10 različitih tekstova; kontrolni pragovi su 5 i 20. Rijetka načela ulaze u zasebne kartice primjera; visok TF-IDF tipfelera nije nalaz.

Ponoviti rangove bez najdužeg potpornog teksta, bez najvećeg izvora i bez najraširenijeg jednakog citata; prikazati osjetljivost na površinski oblik naspram leme. Vremenski kontrast ostaje opis arhive i nakon tih kontrola.

Izlaz: poravnate ljestvice pojmova s brojem tekstova i razlikovnim rezultatom; dodatna tablica svih kandidata.
Rezervni ishod: učestalosti i pregledani konteksti kada usporedive skupine nisu dovoljno velike.

Od vrijednosne formule do jezične veze

Pitanje: jesu li solidarnost, Europa, obitelj ili sloboda povezane u više različitih obrazloženja ili se ponavlja ista politička formulacija? Postojeći NPMI ostaje referenca; novi doprinos jesu izvorni nizovi riječi i klasifikacija njihove funkcije. [3; L1]

Operativni postupak

1. Iz potpunoga slijeda tokena unutar svake rečenice izvesti bigrame i trigrame. Izvorni niz sačuvati uz lematizirani. Fraze poput socijalnoga tržišnog gospodarstva i općega dobra prepoznati pravilima najduljega podudaranja. Četiri ili više riječi dodati samo kao unaprijed navedenu frazu.

2. Odvojiti usmjerene susjedne riječi od neusmjerenog supojavljivanja u rečenici. Niz nastao nakon brisanja međuriječi nije izvorni bigram. Povezivanje udaljenih dokaznih odlomaka nije dopušteno.

3. Potporu fraze brojiti jednom po točnom tekstu. Uz n navesti udio najveće jednake rečenice i broj tekstova preostalih nakon njezina uklanjanja. Zasebno provjeriti jednakost slijeda riječi bez interpunkcije.

4. Za unaprijed zamrznut skup pojmova usporediti NPMI s phi koeficijentom na istoj binarnoj matrici rečenica. U matrici moraju ostati i rečenice bez ijednog od odabranih pojmova; prazni redci ne smiju nestati pri pretvorbi. Nedefinirana vrijednost ostaje nedostajuća. [3, 5]

5. U glavnu tablicu ulaze veze s potporom barem 10 tekstova. Za svaku narativno istaknutu vezu pročitati do 10 različitih potpornih tekstova, sve ako ih je manje, uključujući barem jedan rubni ili negativni slučaj kada postoji.

Čitanje funkcije

Svaki pregledani slučaj označiti kao nabrajanje vrijednosti, povezano obrazloženje, razlikovanje pojmova, osporavanje, navod bez jasne atribucije ili neodređeno. Ista fraza u citatu i njezino pobijanje ne daju jednak sadržajni nalaz.

Izlaz: ljestvica 15-20 fraza te kartice šest pregledanih odnosa. Ako mreža do 20 pojmova ostane čitljiva, debljina veze prikazuje samo jednu navedenu mjeru, a oznaka broj tekstova. Središnjost mreže neće se tumačiti kao ideološka važnost.

Rezervni ishod: tablica odnosa bez mreže. Veza koja nestane nakon uklanjanja jedne formulacije opisuje njezin odjek; nije dokaz široko raspršenog argumenta. Odsutna veza nije dokaz nespojivosti ideja.

Kada načelo postaje javni argument?

Glavni sadržajni modul razdvaja spominjanje, objašnjenje načela i primjenu na konkretno pitanje. Jedan tekst može sadržavati više razina i više suprotstavljenih glasova. Ne ocjenjuje se politička ispravnost niti iskrenost aktera.

Sloj koda	Kriterij za potvrdu	Granični slučaj
Demokršćanski referent	Izričit naziv ili nedvosmislena veza u okolnom iskazu	Kršćansko ili konzervativno nije automatski demokršćansko.
Identitetska uporaba	Pripadnost, pozicioniranje ili opis tradicije kao političke oznake	Spominjanje naziva stranke može biti samo vijest o događaju.
Načelo: imenovano / objašnjeno	Prepoznatljiv naziv / iskaz koji razlaže njegovo značenje	Personalističko vodstvo nije dokaz personalističkog načela.
Problem ili područje	Određeno društveno pitanje, institucija, odnos ili odluka	Općenito obećanje boljeg društva nije određena primjena.
Argumentacijska veza	Načelo služi kao izričit razlog, kriterij ili prigovor uz problem i prosudbu	Dvije riječi u istom odlomku nisu dovoljne.
Status	Potvrđeno; nije nađeno u dostupnom tekstu; nije moguće procijeniti	Prekratak isječak i nejasan govornik ne kodiraju se kao nula.

Početni sadržajni rječnik

Načela i vrijednosti: ljudsko dostojanstvo, opće dobro, solidarnost, supsidijarnost, sloboda i odgovornost, pravednost, sudjelovanje. Pojmovi služe pronalaženju kandidata; značenje potvrđuje iskaz. [8]

Politička i programska uporišta: demokratski pluralizam, europska suradnja, socijalno tržišno gospodarstvo te odnos religije i politike. Voditi ih odvojeno od socijalnih načela; EPP-ova platforma iz 2012. daje jedan dokumentirani primjer njihova povezivanja. [9]

Područja primjene: rad i gospodarstvo; siromaštvo i socijalna zaštita; obitelj i obrazovanje; savjest i prava; organizacija vlasti; Europa i međunarodni odnosi; druga područja otkrivena pilotom.

Nova kategorija može nastati tijekom pilota, uz definiciju i negativni primjer. Nakon zamrzavanja kodne knjige ne dodaje se samo zato što bi proizvela poželjan nalaz; promjena zahtijeva novu verziju i ponovno kodiranje zahvaćenih jedinica.

Povezana tvrdnja, jasan nazivnik

Za svaki kandidat zapisati **tko govori, o kojem problemu, na koje se načelo poziva, kakvu prosudbu ili mjeru obrazlaže i gdje je dokaz u tekstu**. Rečenica je početni raspon; neposredni kontekst smije ga proširiti kada veza ostaje provjerljiva.

Primjeri odluke za kodere

Sljedeći su primjeri namjerno konstruirani za kodnu knjigu. Nisu citati ni novi nalazi iz korpusa.

Konstruirani iskaz	Predložena odluka
Naša je stranka demokršćanska; važne su nam obitelj i solidarnost.	Identitet i imenovanje vrijednosti; konkretna primjena nije nađena.
Zbog dostojanstva radnika, koje povezujemo s demokršćanskim načelima, tražimo sigurnije uvjete rada.	Povezana primjena: dostojanstvo, uvjeti rada, zahtjev i izričit razlog.
Stranka se zove demokršćanskom, ali svojim odlukama zanemaruje solidarnost.	Kritika dosljednosti. Primjena se potvrđuje tek ako dostupni kontekst određuje odluku ili problem.
Solidarnost je važna. U drugom dijelu članka piše o izborima.	Nema dokazane veze s izborima ni automatske atribucije demokršćanstvu.

Tri odvojena rezultata

Udio tekstova s nađenom primjenom: svaki odabrani točan tekst najviše jednom u brojniku; nazivnik su svi tekstovi obuhvaćeni procjenom. Na uzorku koristiti težine sa str. 13. Uz potvrđeno uvijek prikazati neprocjenjivo; ne brisati ga iz nazivnika bez prikaza alternativnog izračuna.

Matrica načelo × problem: ćelija broji tekstove s barem jednom potvrđenom vezom tog para. Više načela i problema može postojati u istom tekstu. Ćelije se ne zbrajaju u ukupan broj tekstova niti u 100%.

Dubina obrazloženja: prikazati odvojeno samo imenovanje, razlaganje značenja i konkretnu primjenu, uz preklapanja. Ne praviti jedinstveni bodovni indeks kvalitete, autentičnosti ili relevantnosti demokršćanstva.

Izlaz: matrica veza i četiri do šest kontrastnih kartica argumenta, uključujući negativni primjer. Bez dostatne pouzdanosti ljudskog kodiranja ostaju kartice i precizno ograničen opis pregledanog materijala.

Kritika čega, iz čije perspektive?

Jedinstvena ocjena pozitivnog ili negativnog teksta može pomiješati tradiciju, stranku, osobu i konkretnu mjeru. Zato je jezgra ovoga modula **stav prema određenom cilju**, a leksički sentiment samo moguća pomoćna mjera. [4; L1, str. 14]

Primarna analiza: kodiranje iskaza

Za svaki interpretabilni iskaz kodirati cilj: demokršćanska tradicija, konkretna stranka ili osoba, načelo, javna politika ili drugi cilj. Govornu ulogu odrediti iz atribucije: citirani akter, autorski/novinarski glas, kolektivno priopćenje ili nejasno. Ne zaključivati govornika iz pukog spomena imena.

Stav prema cilju: afirmacija, kritika/odbacivanje, mješovit stav, opis bez vrednovanja ili neodređeno. Odvojeno označiti samopripadnost i osporavanje dosljednosti. Neslaganje sa strankom nije automatski negativan stav prema tradiciji.

Prikaz: tablica kontrasta unutar istog iskaza ili tekstualne skupine, s brojem potvrđenih slučajeva. Za udjele koristiti tekstove s procjenjivim ciljem i jasno navesti taj uži nazivnik, uz udio neprocjenjivih u punom uzorku. Bez rangiranja građana, publika ili političkog utjecaja.

Dopunski pilot: hrvatski leksički sentiment

Lokalno postoji CroSentiLex; LiLaH je mogući drugi resurs nakon provjere potrebnih kategorija. Engleski AFINN, Bing i NRC iz primjera knjige ne primjenjuju se izravno na hrvatski tekst. Prije uporabe provjeriti format, duplikate, proturječne oznake i verziju resursa. [4; L4]

U pilotu mjeriti pokrivenost tokena, broj prepoznatih riječi po rečenici i doprinos najutjecajnijih riječi. Probni rezultat tona jest (broj pozitivnih - broj negativnih) / broj prepoznatih polarnih tokena. Kada je taj nazivnik nula, rezultat je nedostajući. Slaba pokrivenost zasebno se označuje.

Provjeriti ne, nije, nikad, bez, navodnike, ironiju i suprotne veznike. Ne okretati mehanički polaritet svih riječi nakon negacije. Ako se izvodi sentiment, iz razvojnog materijala izdvojiti barem 80 raznolikih iskaza, po mogućnosti unutar 60 pilot-tekstova sa str. 13. Usporediti rezultat s čitanjem, dokumentirati pogreške i zamrznuti pravila prije neovisne provjere.

Uvjet uključivanja: ton ulazi u dopunu samo ako donese interpretabilnu informaciju povrh kodiranog stava. U protivnom ostaju nalaz o ograničenju leksikona i primjeri; ne objavljuje se prividna ljestvica podrške demokršćanstvu.

Trajan argument ili kratki odjek?

Pitanje: pojavljuje li se isti sadržaj u više tekstova, formulacija i razdoblja? Nadogradnja se odnosi na trajnost konkretnoga jezičnog ili kodiranog sadržaja; osnovna vremenska serija vidljivosti već postoji. [L1-L2]

Četiri mjere koje se čitaju zajedno

Raspon kroz vrijeme: broj tromjesečja s pojavom / broj tromjesečja s dostupnim uključenim tekstovima unutar prikazanog režima i platforme. Uz to prikazati broj potpornih tekstova po ćeliji. Prisutnost skupine pratiti kroz sve njezine zapise, ne samo datum predstavnika; jednom po ćeliji, uz nezbrojivost kroz vrijeme. Mjera ne izjednačuje mali i veliki uzorak.

Koncentracija izvora: udio potpore koji dolazi iz najvećeg imenovanog izvora i broj ostalih izvora. Nepoznati izvori zasebno; rezultat nije broj različitih govornika. Povezivanje source_name potrebno je prije ove mjere.

Koncentracija formulacije: udio tekstova koji sadrže najčešću jednaku potpornu rečenicu, uz kontrolu nizom riječi bez interpunkcije. Rukom pregledati vodeće primjere parafraza; automatska različitost teksta ne dokazuje različitost argumenta.

Osjetljivost na vrh: izostaviti najbrojniji potporni mjesec, najveći izvor i vodeću formulaciju, svako zasebno. Zabilježiti mijenja li se smjer usporedbe i koliko potpore ostaje. Ne birati samo kontrolu koja održava prvotni zaključak.

Pravila usporedbe

Vremenske prikaze razdvojiti na režime prije i od 1. travnja 2024. Posljednji mjesec završava 10. rujna 2026. Za usporedbu posljednjih godina koristiti jednake pune mjesece; nepotpunu 2026. ne uspoređivati s cijelom 2025. Arhivski datum ne dokazuje datum nastanka ni smjer širenja izjave.

Primarni opis na webu; druge platforme zasebno prema veličini i pokrivenosti. U ćelijama s manje od 20 jedinica pokazati broj i oznaku malog obuhvata. Nula se razlikuje od nepostojanja usporedivih podataka. Načela kodirana samo na uzorku ne pretvarati u glatku mjesečnu seriju.

Uloga postojećih tema

Deset NMF tema služi navigaciji i provjeri gdje argumenti presijecaju postojeće kategorije. Novi LDA model razmatra se samo ako pilot duljih koherentnih tekstova otkrije nerazriješenu sadržajnu podjelu. Koristi brojanja, unaprijed zadane k = 8, 10, 12 i tri početka; dokumentira stabilnost i primjere. Kratki spojeni prozori i promjena etikete nisu razlog za novi model. [6]

Kako do udjela kojima se može vjerovati

Leksički moduli mogu se izvesti odmah. Kvantifikacija složenih sadržajnih kodova traži dokumentiranu procjenu čitatelja. Postojeći razvojni skup od 140 konteksta koristan je za učenje pravila. Postojećih 200 slijepih jedinica potječe iz preostalih 1.556 približnih klastera; njihovi ponderi ne predstavljaju svih 2.253 točnih tekstova. [L3]

Predloženi novi dizajn za M3 i M4

Pilot: dvije osobe neovisno kodiraju 60 tekstova iz razvojnog materijala, ciljano uključujući rijetke pojmove, negaciju i nejasnu atribuciju. Usklađuju definicije i dopunjuju negativne primjere. Pilot nije procjena udjela.

Glavni uzorak: 400 točnih tekstualnih skupina iz punog okvira od 2.253. Stratumi: A1 naspram ostalih putova × web naspram ostalih platformi × režim prije/od 1. 4. 2024. Pripadnost skupine odrediti metapodacima njezina fiksnog predstavnika. Za grupu s više režima ili platformi sačuvati i zasebnu oznaku višestruke prisutnosti.

U svakom nepraznom stratumu prvo dodijeliti min(10, N_h), zatim ostatak do 400 proporcionalno preostalom broju jedinica, metodom najvećih ostataka uz ograničenje kapaciteta. Nasumični izbor bez vraćanja, zabilježen seed 20260920. Težina w_h = N_h / n_h. Uzorak se bira iz cijelog okvira, a ne samo iz tekstova s rječničkim pogotkom.

Dva čitatelja kodiraju istih 400 tekstova bez prikazanih AI oznaka i rezultata drugog čitatelja. Sačuvati prvotne odluke, slaganje, razloge neslaganja i usuglašenu odluku. To znači **800 neovisnih kodiranja**, uz pilot i razrješenje sporova; vrijeme po jedinici izmjeriti u pilotu.

Pouzdanost, procjena i neizvjesnost

Za osnovne kodove prikazati matricu slaganja, postotak slaganja i Krippendorffov alpha, s brojem slučajeva po klasi. Predloženi projektni kriterij za kvantitativni glavni nalaz jest alpha ≥ 0,80; ako je mjera nedefinirana ili broj pozitivnih slučajeva manji od 20, zadržati oprezan prikaz brojeva i primjera. To su projektna pravila za pregled, ne univerzalni standardi.

Udjele računati iz usuglašenih kodova s težinama i intervalima koji uvažavaju stratificirani izbor te konačan okvir. Interval opisuje nesigurnost uzorkovanja unutar zamrznute zbirke; ne pokriva pogreške odabira arhive ili kodiranja.

Novi uzorak može sadržavati ranije pročitane razvojne tekstove: valjan je za opisnu procjenu uz slijepo ljudsko čitanje, ali nije automatski neovisni test klasifikatora. Eventualni klasifikator mora imati zaseban netaknut test, bez podijeljenih kopija i citata između razvoja i testa.

Što mora izdržati svaki važan nalaz

Rizik	Obvezna provjera	Ako nalaz ne izdrži
Korpus je izabran riječima koje zatim analiziramo	Cjelina prema A1; selekcijsko nazivlje odvojeno od ostalih riječi	Nalaz označiti kao povezan s pravilom uključivanja.
Ista izjava dominira različitim člancima	Točni tekstovi, najčešća rečenica, niz riječi bez interpunkcije, postojeći pragovi sličnosti	Prikazati odjek formulacije; ne tvrditi širinu argumenta.
Lokalni prozor izostavlja obrazloženje	Na istim kodiranim tekstovima usporediti lokalni i cijeli dostupni opseg	Prikazati koliko je kodova osjetljivo na skraćenje; ne zaključiti odsutnost.
Duljina i sastav izvora stvaraju razliku	Udio tekstova, normalizirana učestalost, web zasebno, izostavljanje najvećeg izvora	Sužavanje zaključka na uspoređeni sastav zbirke.
Lema ili šablona proizvodi lažni pojam	Površinski oblik, izvorni raspon, pregled vodećih i rubnih pogodaka	Ispraviti izvedeni sloj uz novu verziju; izvorno izdanje sačuvati.
Mali uzorak stvara uvjerljivu sliku	Brojevi uz sve udjele; jednake vremenske granice; neprocjenjivo vidljivo	Brojevi i kartice umjesto rangiranja i glatkih krivulja.
Ljudsko i automatsko čitanje ne daju iste kodove	Odvojeni pilot i test; metrike po kodu, ne samo ukupno slaganje	Automatski sloj ostaje tražilica kandidata.

Dodatno pravilo za automatizaciju sadržajnih oznaka

Ako se nakon pilota predloži automatsko kodiranje svih tekstova, za svaki kod tražiti neovisnu provjeru preciznosti i odziva, s najmanje 20 pozitivnih referentnih slučajeva. Početni projektni prag za oba pokazatelja jest 0,80; prikazati intervale i stvarne brojeve pogrešaka. Prolazak nije jamstvo za druge platforme ili razdoblja.

Rijetki kodovi ostaju ručno pregledani. Udio automatskih oznaka ne izjednačavati s procijenjenim stvarnim udjelom bez obrade klasifikacijskih pogrešaka. Glavna procjena sadržaja može ostati na ponderiranom ljudskom uzorku i kada postoji klasifikator.

Najjača dopuštena tvrdnja: određena argumentacija pojavljuje se u pregledanom ili procijenjenom dijelu odabrane arhivske zbirke. Ovim podacima ne mjerimo potporu građana, iskrenost političara, uzročni učinak ideja ni reprezentativan udio svih medija.

Jedna istraživačka priča, osam prikaza

Vizualni jezik slijedi izvorni PDF: topla svijetla podloga, tamnozelena tipografija, bakreni naglasci, serifni naslovi i čitljive tablice. Svaki prikaz počinje pitanjem, a završava jedinicom, nazivnikom, izvorom i najvažnijom granicom tumačenja.

Prikaz	Sadržaj i vizualni oblik	Uvjet za prikaz
A. Rječnik tradicije	Dvije poravnate ljestvice: raširenost i razlikovnost; broj tekstova uz pojam	M1; zamrznut rječnik i dvije usporedive skupine
B. Formule i fraze	Točkasti prikaz potpore prije i nakon uklanjanja vodeće formulacije	M2; isti nazivnik i navedeni preostali broj
C. Karta odnosa	Mala matrica ili mreža do 20 pojmova; mjera veze i potpora	M2; pregledan smisao istaknutih veza
D. Načela i problemi	Matrica potvrđenih veza; udjeli samo uz ponderiranje i pouzdanost	M3; validirani kodovi, vidljiva višestruka pripadnost
E. Anatomija argumenta	Kartice: načelo, problem, prosudba, govornik, dokaz i protuprimjer	M3; čitanje dostupnog konteksta
F. Dva cilja, različit stav	Usporedne oznake stava prema tradiciji i akteru u istom slučaju	M4; jasna atribucija; bez prosječnog sentimenta teksta
G. Trajnost sadržaja	Matrica tromjesečja uz broj potpornih tekstova i granicu režima	M5; za kodirani uzorak samo dovoljno velike cjeline
H. Koliko je priča stabilna?	Sažeta tablica nalaza, kontrola i promjene tumačenja	Svi moduli; uključiti i neuspjele provjere

Predložena struktura konačne dopune

Otvaranje, 2 stranice: istraživačko pitanje, nova vrijednost u odnosu na izvještaj i sažetak stvarnih nalaza. **Rječnik i formule, 3-4 stranice:** A-C. **Načela, argumenti i stav, 4-5 stranica:** D-F. **Trajnost i provjere, 2-3 stranice:** G-H. **Metode i izvori, 3-4 stranice:** jedinice, kodna knjiga, uzorak i ograničenja. Ukupno približno 14-18 stranica, ovisno o potpori nalazima.

Ne popunjavati predloške izmišljenim postocima ili primjerima koji se prikazuju kao stvarni. U ovom planu nema simuliranih empirijskih grafikona. U konačnom dokumentu isti pojam zadržava istu oznaku, a svaki citirani ili parafrazirani slučaj ima privatni dokazni trag.

Radni slijed s jasnim završecima

Korak	Posao i ovisnost	Mjerljiv izlaz
1. Zamrznuti specifikaciju	Zabilježiti verziju plana, ulaze, opsege teksta i kriterije prikaza	manifest ulaza, registar pitanja i jedinica
2. Povezati i urediti tekst	Iskoristiti postojeće predstavnike i tokene; povezati izvor; anotirati proširenja	documents, tokens, tablica nedostajućeg i izvještaj povezivanja
3. Izvesti M1 i M2	Zamrznuti fraze i pravila nakon pregleda pogrešaka	rječnički profili, fraze, tablice veza, kartice kandidata
4. Pilotirati kodnu knjigu	Dva čitatelja; definicije načela, veze, cilja i atribucije	codebook v1, pilot odluke i razlozi izmjena
5. Kodirati glavni uzorak	Nasumičnih 400 skupina; dvije neovisne odluke po jedinici	dizajn uzorka, koderske odluke, slaganje i usuglašeni kodovi
6. Sastaviti M3-M5	Ponderirane procjene i raspršenost; provjere stabilnosti	tablice nalaza s nazivnicima, neizvjesnošću i rezervnim ishodom
7. Urediti dopunu	Odabrati prikaze koji odgovaraju na pitanja; provjeriti svaku tvrdnju	samostalan PDF, izvori, agregati, registar tvrdnji i provjera svih stranica

Dvije razine izvedbe

Računalna i istraživačka jezgra: M1, M2, leksička raspršenost M5, kodna knjiga i odabrani argumentacijski primjeri s navedenim načinom čitanja. Ako ljudski čitatelji nisu uključeni, rezultat nosi taj status i ne prikazuje potvrđene udjele složenih kodova.

Puna sadržajna dopuna: prethodno plus neovisno kodiranje M3/M4 i ponderirane procjene. Potreban je angažman dvaju čitatelja; trošak se procjenjuje prema pilotu, broju i duljini tekstova. Neizvediv dopunski model ne zaustavlja osnovne module.

Organizacija novih izlaza

Predloženi kod: studies/demokrscanstvo-barometar/text-addendum/. Agregati i dokumentacija: output/demokrscanstvo-text-addendum/v1/. Tekstovi, identifikatori, rasponi i pojedinačne koderske odluke ostaju u novoj privatnoj radnoj mapi.

Izlazni paket uključuje README, manifest, verziju rječnika i kodne knjige, renv/sessionInfo za R, seed, tablice, slike i registar tvrdnji. Postojeći PDF i njegova zamrznuta izdanja ostaju referentno polazište. Ovaj sadašnji dokument jest plan za pregled, a ne izvršena dopuna.

Jedinice, nazivnici i provedba u R-u

Rezultat	Definicija	Kritična provjera
Dokumentna učestalost	Broj točnih tekstova s pojmom / svi analizirani točni tekstovi istog opsega	Tekst se broji jednom; nedostajući opseg nije nula.
Normalizirana frekvencija	10.000 × broj pojavljivanja / broj zadržanih tokena	Jednaka pravila filtriranja; zasebno objaviti nazivnike.
TF-IDF	tf(t,d) = n(t,d) / zbroj svih n u d; idf(t) = ln(N / df(t)); umnožak tf i idf	N i df iz istog zamrznutog skupa nepraznih dokumenata. Ovo nije postojeća sublinearna NMF težina.
NPMI	ln[p(a,b)/(p(a)p(b))] / -ln[p(a,b)]	Isti svemir rečenica; samo 0 < p(a,b) < 1.
Phi	(a×d - b×c) / sqrt[(a+b)(c+d)(a+c)(b+d)]	a: oba pojma; b/c: samo jedan; d: nijedan. Nulti nazivnik ostaje nedostajući.
Udio potvrđene primjene	Zbroj w_i × I(potvrđeno) / zbroj w_i	Ponderi iz uzorka svih točnih tekstova; neprocjenjivo posebno prikazano.
Potpora para načelo-problem	Tekstovi s barem jednom potvrđenom vezom toga para	Matrica je višestruka; njezine ćelije nisu particija korpusa.

Predloženi alati, bez nepotrebne promjene postojećeg sustava

dplyr / tidyr: povezivanje i sažeci; **udpipe:** postojeće hrvatske leme i nova proširenja; **tidytext:** frekvencije, bind_tf_idf() i pretvorbe matrica; **tidylo:** bind_log_odds(); **ggplot2:** prikazi. Za phi koristiti eksplicitnu matricu s potpunim svemirom rečenica ili provjeriti da poziv widyr daje isti nazivnik. [1-3, 5, 7]

survey: procjene uz stratume, pondere i korekciju konačne populacije. **topicmodels::LDA():** samo uvjetna provjera na brojanjima. Postojeće NMF komponente i IDF ostaju pohranjene bez zamjene. Zaključati stvarno korištene verzije u provedbi, ne preuzimati pretpostavljene verzije iz primjera knjige. [6]

Obvezne strojne provjere: jedinstvenost ključeva; spajanje 1:1; poklapanje tokena i izvornog raspona; nepovezivanje polja; točno brojanje fraza; očuvanje praznih jedinica u nazivniku; zbroj pondera 2.253; reproducibilnost izračuna i brojki prikazanih u PDF-u.

Literatura i trag provjere

Metode su odabrane iz pregledanih mrežnih poglavlja; formulacije pitanja, uzorkovanje, pragovi i odluke o prikazu prijedlog su ovoga projekta. Poveznice provjerene 19. rujna 2026.

1. **Silge, J. i Robinson, D. Text Mining with R, pogl. 1.** Tidy text i veza tokena s metapodacima. Otvoriti poglavlje.

2. **Isti autori, pogl. 3.** Učestalost, dokumentna učestalost i TF-IDF. Otvoriti poglavlje.

3. **Isti autori, pogl. 4, osobito 4.1 i 4.2.2.** N-grami, odnosi riječi i phi. Otvoriti poglavlje.

4. **Isti autori, pogl. 2.** Leksički sentiment, ograničenja negacije i veličine jedinice. Otvoriti poglavlje.

5. **Isti autori, pogl. 5.** Pretvorbe između tablica i matrica. Otvoriti poglavlje.

6. **Isti autori, pogl. 6.** LDA i pregled pripadnosti riječi i dokumenata temama. Otvoriti poglavlje.

7. **tidylo, dokumentacija bind_log_odds().** Regularizirani težinski log-omjer izgleda; usporedba skupa s ostalima. Otvoriti dokumentaciju.

8. **Papinsko vijeće Iustitia et Pax (2004). Kompendij socijalnog nauka Crkve.** Poglavlje IV, posebno 160-163, 164-170, 185-196; pojmovno uporište, ne klasifikator politike. Otvoriti izvor.

9. **European People's Party (2012). Party Platform.** Dio I; političko samorazumijevanje jednoga aktera, povijesno datiran dokument. Otvoriti izvor.

Lokalni izvori

L1. demokrscanstvo-analiticki-izvjestaj.pdf, 20 str., izdanje 1.0, 19. 9. 2026. SHA256 provjeren prema report manifestu; nije mijenjan.

L2. output/demokrscanstvo-analysis/v1/: summary.json, manifest.json, annual.csv, platforms.csv, lexical_summary.json, lexicon.json; privatni documents.jsonl i prepared.json; kod prepare.R. Broj 2.198 odnosi se na neprazno očišćeno polje body, provjereno za ovaj plan.

L3. human_validation_status.json i qualitative_review.md; postojeći protokol 2.0. Izričito razlikuju razvojno čitanje, pripremljeni uzorak i dovršenu validaciju.

L4. resources/README.md i PROVENANCE.csv; lokalni CroSentiLex i LiLaH. Njihova dostupnost nije dokaz valjanosti za politički stav u ovom korpusu.

Status dokumenta: dovršen prijedlog za pregled. Izrađeno uz pomoć Codex AI-ja. Nova sadržajna analiza, ljudsko kodiranje i predloženi grafikoni još nisu izvedeni.